202-2-5211 עיבוד שפה טבעית — תרגיל 1

מועד הגשה: 23 **בינואר** 2024, 13:59

משקל התרגיל: 8 נקודות מהציון הסופי. מספר הנקודות של כל שאלה מופיע בסוגריים. על־מנת לקבל ניקוד מלא יש לענות על **כל** ההוראות בשאלה, **ורק עליהן**.

יש להגיש את התרגיל **לבד**. ניתן להתייעץ עם סטודנטים.ות אחרים.ות אך בסופו של דבר על הפתרון להיות עצמאי.

1 עיבוד טקסט (1)

הורידו מאתר הקורס (לשונית מבואות) את תסריט הסרט "הקוסם מארץ עוץ" ("קורפוס עיבוד טקסט (I) ל־3/1"). כמה מילים בתסריט מתחילות ברצף התווים `ea`? אין להתחשב בסוג האות (case-insensitive), ויש לכלול גם את המילים שהן בדיוק רצף התווים, במידה ויש. ענו עבור **(א)** תבניות (types); **(ב)** תמניות (tokens).

2 מטריקות (3)

2.1 מטריקת F

1. הוכיחו (מתמטית) כי מטריקת F_1 לעולם לא תהיה גדולה מהממוצע החשבוני של מטריקות ה־Precision וה־Recall. לא מדובר בהוכחה ארוכה.

2. האם הטענה נכונה עבור כל מטריקת F_β, עם β שרירותי? הוכיחו או הפריכו.



איור 1: מקלדת עם תווים עבריים

2.2 מרחק עריכה

נגדיר את מרחק "דוונשטיין" בין שתי מחרוזות כך: מחיר של הוספת תו הוא 1; מחיר של מחיקת תו הוא 1; פעולת שיכול תווים (transpose) אינה חוקית; פעולת החלפה בין תווים (substitution) עולה 1 אם ורק אם התווים המוחלפים שכנים באותה שורה במקלדת עברית סטנדרטית (ראו איור 1), 1.5 אם התווים נמצאים באותה שורה אך אינם שכנים, ואחרת 2. לדוגמה, החלפת נ־מ עולה 1; החלפת נ־ב, נ־צ עולות 1.5 כל אחת. החלפת נ־ע, נ־פ עולות 2 כל אחת.

מהו מרחק דוונשטיין בין המחרוזת **עיבודשפה** והמחרוזת **מכביחיפה**? כיללו את טבלת המעבר המלאה בתשובתכסן.

3 רגרסיה לוגיסטית (4)

מומלץ לפתור ידנית. בכל מקרה נא לא להגיש קוד.

בשאלה זו נאמן מערכת לזיהוי משפטים משירים של שלמה ארצי. עבור כל דוגמא נחלץ את הפיצ'רים הבאים:

- פיצ'ר בינארי: האם יש במשפט פועל (Verb) בזמן עבר או כינוי גוף (Pronoun) בגוף שני (רשימת כינויי הגוף: אתה, את, אתם, אתן. הניחו שחילוץ הפיצ'ר מתרחש אחרי פעולת כלי שיודע להבחין בין כינוי הגוף "את" למילת היחס "את", וכלי שיודע לנתח פעלים ולזהות את הזמן שלהם באופן מדויק. "או" כאן הוא אינקלוסיבי.)
- מספר מילים עם תחילית היחס ב (הניחו שיש לנו מודל קדם־חילוץ שיודע לאתר אותה)
- מספר המילים במשפט, פחות 5 (מילים מופרדות־רווח בלבד)
- מספר מילות הזמן, מתוך הרשימה הסגורה הבאה: עכשיו, תקופה, כרגע, כבר, מייד, עדיין.

1. חשבו את ערכי הפיצ'רים $(\mathbf{f})$ עבור שלוש הדוגמאות בסט האימון להלן. ניתן להניח כי מנקים סימני פיסוק כחלק מתהליך הקדם־עיבוד.
   - היתה תקופה כזו שהאושר בא בזעם $(y = 1)$
   - את עולמי עם שחר, את לי כל היום $(y = 0)$
   - עכשיו יש את הזמן במזרחית $(y = 1)$
2. חשבו שלוש איטרציות עדכון של מודל רגרסיה לוגיסטית העובר על שלוש הדוגמאות לעיל לפי הסדר. המודל מאותחל לערכים הבאים:

$$\theta^{(0)} = \langle 0, 0, 0, 0, 0 \rangle$$

   קצב הלמידה תלוי במספר האיטרציה ונתון על־ידי:

$$\eta(t) = \frac{0.8}{t}$$

   אפשר לעגל כל חישוב סיגמויד וכל קצב למידה למקום השני אחרי הנקודה, את ערכי הפרמטרים נא לא לעגל. כתבו את כל השלבים עבור כל האיטרציות.

3. מה חוזה המודל שלכם עבור דוגמת המבחן להלן?
   - אם כבר אז שיירד כאן שלג

4 בונוס: משוב (+1)

על־סמך השבועות הראשונים של הסמסטר: אילו שינויים תרצו לראות באופן ההוראה על־מנת להבין את החומר יותר בקלות?

5 העשרה/הכנה: מידול שפה באנגראמים (0)

ללא ציון, ללא בדיקה. נדון בזה בשיעור. חומר עזר אפשרי: פרק 3 בסטנפורד.

מידול שפה הוא הבעיה של חיזוי ההסתברות עבור טקסט נתון:

$$P(w_1, w_2, \ldots, w_N)$$

ואשר לרוב נהוג לפרק לחיזוי מילה־מילה:

$$= P(w_1|\text{START}) \cdot P(w_2|w_1) \cdot \cdots \cdot P(w_k|w_1, \ldots, w_{k-1}) \cdot \cdots \cdot P(w_N|w_1, \ldots, w_{N-1}),$$

כאשר START הוא תבנית מיוחדת שלא מופיעה בטקסט ומסמנת תחילת מחרוזת.
מודל שפה מסוג **n-gram** הוא מודל שבו אנו מפשטים את הנחת התלות של כל מילה במילים הקודמות, ומחשיבים רק את $n-1$ המילים שקדמו לה:

$$P(w_k|w_{k-n+1}, \ldots, w_{k-1}).$$

את פרמטרי ההסתברות נחשב לפי שכיחויות בקורפוס אימון, כך שנספור את כל רצפי המילים באורך n ונאמוד הסתברות באמצעות יחס ההופעה של המילה ה־ k במקום ה־ n:

$$\hat{P}(w_k|w_{k-n+1}, \ldots, w_{k-1}) = \frac{\text{COUNT}(\langle w_{k-n+1}, \ldots, w_{k-1}, w_k \rangle)}{\sum_w \text{COUNT}(\langle w_{k-n+1}, \ldots, w_{k-1}, w \rangle)}.$$

1. האם זהו מודל גנרטיבי (generative model) ? הסבירו בקצרה.
2. אומדני הסתברויות של רצפים באורך **בדיוק** n בלבד לא יאפשרו לנו לכלול בחישוב ההסתברות הכוללת את תחילת הטקסט. הסבירו בקצרה למה, והציעו אוסף נוסף של פרמטרים שנידרש לשמור כך שנוכל לכלול גם אותו. (יש יותר מתשובה אפשרית נכונה אחת.)
3. בהתאם לתשובתכם בסעיף הקודם, איזה חלק יחסי של הפרמטרים מהמודל תופסים הפרמטרים מהאוסף החדש? בטאו כפונקציה של הגדלים הבאים או חלק מהם בלבד: n, גודל קורפוס האימון M, מספר המסמכים בקובץ האימון D, גודל אוצר המילים V.
4. מה הסכנה שעלולה לנבוע מפגישת n-gram בטקסט המבחן שלא הופיע בקורפוס האימון? הציעו שיטה אפשרית לפתרון הקושי.